多 Agent 编排：成果总览

2026 年 11 月 6–9 日 · 七批实验 168 次运行 + 一条全链路 · changkong34@qq.com

> 一句话。决定成败的是"判据能不能被机器核对"，不是"模型够不够强"。
>
> 需求写得含糊，任何后端都会反复返工；需求写得可锚定，便宜的后端也能一次做对。

三条结论

1. 需求写法的效果是 U 形，不是越多越好。 最优点在"说清改哪个文件、做什么"；不给锚点必然返工，给两个反而略差，写得再长不会更好。
2. 失败的机制只有一个：判据不可判定。 80 次规划运行中 47 次拒稿，错误码 100% 是同一类，没有第二种失败形式。
3. 换更强的模型没有换来质量。 同一外壳换后端，三个后端都做对了同一批任务，差异只在速度（慢 1.5–1.7 倍）与成本（差 4 倍）。

七批实验

批次	问的问题	n	结果
一	需求详细程度影响多大？	30	U 形：L1 平均重写 1.00，L3 为 0.00，耗时差 2 倍
二	是不是"长度"或"指代"在起作用？	20	配对实验，两者都排除（3 好 3 坏 4 平）
三	机制是什么？	24	锚点 0 个最差、1 个最优、2 个回升；0 vs 1 的 p = 0.031
四	换个模型版本还成立吗？	6	方向稳、水平漂（L3 从 0.00 变 0.33）
五	换后端，质量/速度变不变（Pro）	36	质量无差；慢 1.68×，p = 0.00014
六	换更轻的档位能快回来吗（Flash）	36	仍慢 1.53×（p = 0.015），只赚回 9%
七	每次任务花多少钱？	16	Flash ¥0.039 / Pro ¥0.155，差 4 倍

两天之后：从"能跑"到"可冻结"

11 月 8–9 日没有做新实验，做的是把实验里那套东西变成别人拿到也能跑的系统。 起因很朴素：真实的对话里跑一次，它失败了，而失败原因不是模型不行。

新增能力	它解决的问题
`apply`	产物只进集成分支，用户看不到变化；以前靠模型手动抄文件——手抄没有冲突检测，也不留记录
`undo`	"这次结果我不要了"要能一句话撤掉，且保留证据
`cleanup` + 心跳	进程卡死后能判活、能回收。判活只看锁与心跳，不看 pid（pid 会复用）
三种模式 `single/parallel/chain`	模式是对执行形态的承诺，写错即拒稿（E022/E023），不再只是标签
`handoff` 溢出转引用	串联时上一阶段的交代超 200 字就落文件、只给摘要，避免上下文被撑爆
办公工具链	docx / xlsx / pptx 的生成与断言全部脚本化：模型只写内容，结构交给脚本
`eta` 选档	按历史每层墙钟估时长，超过 8 分钟转投递，而不是等人猜

真实对话里跑通的链路（各 1 次模型调用，worker 走 `deepseek-flash`）：

任务	耗时	结果
4 个模块实现	67 s	4/4 通过，工作区经 `apply` 落地
文档 .docx	107 s	187 字 / 3 段，断言真跑了（不是模型判的）
表格 .xlsx	64 s	4 行×2 列，值逐格核对
幻灯片 .pptx	70 s	4 页，独立实现（python-pptx）打开校验

这两天修掉 12 处问题，其中 4 处属于同一类：看起来成功了，其实没成。 沙箱卡死被记成"模型做错了"、运行目录跑到了 D 盘没人找得到、判据全被误判成"断言型"、 验收脚本自己留下的 `__pycache__` 把合并挡住——每一条都只在真实运行里露头。

冻结时新增的一条硬规则
判据必须能写成一条没人看也能跑的断言，否则这个任务不进实验集。 判据弱，因变量就带噪声，算出来的成功率不可用——这已经不是工程问题，是效度问题。

这套系统本身

四层结构：契约（把拆解写成可检查的字段）→ 校验（23 条规则，提交前拒稿）→ 执行（每任务独立 worktree，越界即废）→ 验收（判据、diff、文件内容，不给推理过程）。

后端可替换：注册表里每个 worker 声明能力与成本权重，按能力分派、按配额计价。 这条设计让"换模型有没有用"成了一个可测的问题，而不是一个信仰问题。

最有价值的一条工程经验来自踩坑：验收器能力不足时，失败会伪装成"被验收者的错误"。 三次失败全是这样，如果不逐条核对证据，会把系统缺陷记成模型差异。

交付物

文件	内容
`多Agent规划返工-研究报告-2026-11-06.pdf`	第一版：四批 80 次规划运行（需求写法这条线）
`02-增量记录-2026-11-07.pdf`	增量：验收器修复、后端接入、88 次执行运行、成本实测
`03-成果总览-2026-11-09.pdf`	本文，三页
`experiments/FINDINGS.md`	逐批原始结论与局限
`experiments/results*.csv`	七批全部明细数据
`04-设计冻结-v1.9-2026-11-09.pdf`	系统设计与接口规格（v1.9，冻结版）
`orch/` + `tests/`	编排系统：9,491 行、337 个测试
`dist/orch-v1.9.bundle`	git bundle：拷到任何机器上 `git clone` 即可复现

封存包与校验和在 `dist/`；换机器复现的三步见冻结稿 §8.1 或 `docs/REPRODUCE.md`。运行时是纯标准库，不需要装任何包。